

Beacon · KOC 成长伙伴 · 产品说明文档

腾讯 PCG 校园 AI 产品创意大赛参赛作品

配套材料：本文档为主文档；完整 PRD 与 4 份 agent 技术规范见末尾「附录」章节

封面页

项目	内容
作品名称	Beacon · KOC 成长伙伴
参赛赛道	题目5：用AI+社媒流量密码，帮助普通KOC轻松涨粉
选手姓名	张知尧
Demo 链接	https://43-134-72-220.nip.io/
代码仓库	https://github.com/RealZYZhang/koc-agent-v2

注：本demo中有“冷启动”与“热启动”两个版本，分别对应用户新建画像与已有画像的两个登入状态，评委可以切换体验。本demo已经接入LLM。

速览：我们解决什么问题，凭什么能解决

总结：Beacon 是面向 1K- ~ 10K+ 粉丝段视频类 KOC 的 **AI 成长伙伴**，把「画像 → 选题 → 复盘」做成可验证、可追溯的闭环，让早期创作者不靠运气也能专业化运营。

用户面对的问题	我们如何解决	用户能获得什么
账号定位模糊， 不知道自己适合什么主题、面向谁	AI 先消化用户历史视频， 主动提出带证据的画像假设； 画像分「确定 / 个性化 / 待探索」三态，且持续追踪 「还在思考的方向」， 在新内容中探索	通过开场与AI对话拿到一份属于自己的画像， 后续不断对画像更新、调整
选题不切题、缺方法论， 追热点又怕丢失个人色彩	双轴策略：每条建议同时基于 「画像驱动 + 趋势驱动」 交叉判断，强制标注来源 (画像驱动 / 趋势驱动 /	拿到带「热度 / 贴合 / 差异 / 执行」 四维评估、可执行的拍摄简报， 每一句建议都看得到出处

用户面对的问题	我们如何解决	用户能获得什么
	数据驱动 / 历史复盘 / 用户偏好驱动)	
视频发出去后只有冷冰冰的数字，不知道哪里成了哪里没成，更不知道下次怎么改	闭环复盘：发布前的策略快照 vs 实际数据做归因，挖掘评论中的真实诉求，并把验证结果回写画像	拿到一份"成功 / 没达预期 / 受众告诉我们的事 / 下一步"四段式洞察，画像随之自动迭代，AI 越用越懂用户
AI 输出像黑箱，不敢用、用了不踏实	与分析来源标签强绑定：每条 AI 分析至少有1个来源标签，前端用色卡呈现	始终知道 AI 在「凭什么」给建议，建立长期信任

模块一 用户洞察与问题定义

1.1 目标用户

核心用户：早期视频类 KOC（粉丝量 数百-上万）

- 平台：抖音、小红书、视频号等为主，产品本身平台无关
- 创作背景：兴趣驱动、非专业团队、单人或小型组合
- 内容现状：主题尚未稳定，跨多个垂类摸索（如校园生活、美食探店、学习日常）
- 商业目标：希望接到与个人定位贴合的小型商单，把爱好变现
- 关键背景：用户已经有粉丝和内容基础，并非从零起步。AI 的角色不是教小白从头做，而是在其既有素材中引导用户找到方向

典型用户画像 — 小A：在校大三学生，抖音 1000+ 粉，发布校园 vlog 与食堂探店，正在思考是否把考研内容作为新主轴，希望接到校园生活 / 学业相关商单。

1.2 用户痛点

早期 KOC 不是专业团队，没有运营经验，专业技能薄弱。具体表现为：

#	痛点	后果
1	定位模糊：账号主题不明确或仍在探索	账号形象不清晰，受众难匹配，商业价值上不去
2	选题方法论缺失：选题不切题、不够吸引人，制作节奏混乱	完播率、关注率、转发率长期低迷
3	复盘能力弱：没有结构化分析、归因、迭代能力	账号原地踏步，每次发布都像重新赌博

行业空白：当前给视频类 KOC 服务的 AI 工具主要集中在「内容生产自动化（剪辑、配音、数字人）」「爆款工业化复刻」「KOC 营销 SaaS」「数据看板」四类（详见 §2.4 创新与差异化），**没有一款产品聚焦于「早期 KOC 的画像建立 + 战略导航」**。早期 KOC 最缺的恰恰不是更多素材，而是有人帮他想清楚自己是谁、该做什么。

1.3 使用场景

场景 A：建立画像

小A 第一次进入 Beacon。AI 已经分析过她 2-5 条历史视频，开口第一句不是问卷，而是「我看完了你的视频，初步感受到三个特征……」。多轮对话内，小A 验证 AI 的假设、补充顾虑、确认尚在探索的方向（如「考研 vs 校园探店」「希望接什么类型广告」）。最终生成一份「确定 / 个性化 / 待探索」三态的 KOC 画像，三个工作模块解锁。此后小A每次进入Beacon即可看到自己的画像，并能够针对画像中的每一点与 AI 讨论并修改。

场景 B：ideate（拍前选题策划）

小A 想拍「考研期间一日三餐怎么吃才能不困」。AI 拉出她的画像 + 当前趋势数据，给出四维评估（热度 / 贴合 / 差异 / 执行），每条建议都标注来源。小A 觉得钩子太严肃，在右侧 chat dock 追问「能不能轻松一点」，AI 实时调整并解释取舍。最终输出可执行的拍摄简报，并锁定一个重点观察指标作为复盘锚点。

场景 C：retro（拍后复盘）

视频发布后，小A 进入复盘模块。AI 把发布前的策略快照与实际数据并列展示：钩子 命中、完播率不达预期、关注转化超预期且是主要指标。小A 点击完播率卡片向下追问「为什么会在第 12 秒掉」，AI 沿证据链给出回答。复盘结束后画像自动更新，AI 越用越懂她。

模块二 产品方案设计

2.1 产品概述

Beacon 是一个 **结构化 + 对话式双形态** 的 web app：左侧是结构化信息（画像、数据、卡片、图表），右侧是常驻 AI 对话 dock；每一个数据点都是「对话入口」，用户点击即可向下追问。产品端到端做三件事：**建画像 → 给策略 → 做复盘**，完成一次闭环画像就升级一次。


2.2 核心功能

产品由 **4 个工作模块 + 1 个常驻 chat dock** 构成：


模块	解决什么问题	核心能力
Onboarding (首次入场)	定位模糊、 不知道自己是谁	AI 先做功课 → 三态画像 → 多轮高密度对话 → 实时 LIVE 信息栏让用户看到 AI 在记录什么
Profile (我的画像)	画像不可见、无法演化	三态分列展示（确定 / 个性化 / 待探索）、 待探索项独立成列且可点击展开、画像更新历史 strip
Ideate (选题策略)	选题没方法论、 不知道靠不靠谱	双轴评估（画像 + 趋势）→ 4 维指标卡 → 差异化角度 → 节奏与 CTA → 重点观察指标锚点

模块	解决什么问题	核心能力
Retro（复盘）	数据冷冰冰、不知道哪里成了	策略快照 vs 实际数据并排对比 → 3 张洞察卡 → 评论聚类 → 写回画像
Chat dock（常驻对话）	想对任何元素追问	Orchestrator 路由 + 5 场景角色化 prompt + 来源标签 强校验

2.3 产品架构图




核心数据闭环：



每一步的中间产物都持久化为 JSON，可在 demo 中被评委直接查看。


2.4 交互流程

2.4.1 关键路径示意：



2.4.2 产品原型图：


步骤1: Landing



步骤2: Onboarding



步骤3: Profile



步骤4: Ideate

Beacon

BETA

工作区

首页

我的画像

选题策略

复盘

下一期想拍什么

搜索内容、insight、画像

YOUR IDEA

草稿 · 刚才更新

下一期想拍：「考研图书馆里那个永远占座的人到底是谁」——用半纪录片半搞笑的口吻，跟拍我自己一周的图书馆抢座经历。

让我改一改这条 idea

给我 3 个相邻方向

收藏到选题库

生成完整拍摄简报

01 · 热度匹配度

72 / 100

推流期 · 还有 6-10 天窗口

02 · 画像贴合度

85 / 100

高度贴合 · 还能验证待探索项

03 · 差异化空间

81 / 100

4 个可切入的独特角度

04 · 执行要点

READY

开头 / 节奏 / CTA / Tag 已生成

01 · 热度匹配度 · 趋势驱动

这个主题正在涨

过去 7 天「考研日常 / 图书馆类」的发布量、互动量都在快速上升，但供给还没填满需求。建议尽快发。

近 7 天发布量 +34% ↑

近 7 天互动量 +58% ↑

供给 / 需求比 0.81 ↓

<1 = 内容供给不足，红利期

同类爆款门槛 8.4 万赞

同类话题热度走势 · 近 13 天

看 12 个 TOP 同类爆款

DEMO

0. New user

1. Onboard

→ Profile

→ Ideate

→ Retro

→ Home

A 小A

1,238 粉丝 · 抖音

STRATEGY COPILOT

在帮你打磨这条选题

Beacon

你提的这条 idea，我评了四个维度。整体推荐做。

Beacon

重点：这条会直接验证你画像里那个待探索项——「生活向 vs 考研向」。看完反响你就能下决定。

你的画像

近 7 天平台趋势

Beacon

我用绿色 / 蓝色标了每条建议来自哪——画像还是趋势——你不用猜我在想什么。

下一步可以问

开头钩子还能怎么改

如果做成 vlog 而不是纪录片呢

推荐 3 个相邻选题

问点关于“在帮你打磨这条选题”的事...

AI 会引用你的画像与最近数据。了解隐私

发送

换行

步骤5: Retro

Beacon

BETA

工作区

首页

我的画像

选题策略

复盘

最近视频表现

搜索内容、insight、画像

最近这条没炸，我来告诉你为什么。

我把发布前的策略和发布后的真实数据放在一起对比。点任何一个数字、insight 或建议，可以继续追问我。

图书馆永远占座的那个人

今天 · 4,820 播放

低于基线

考研三个月，我的桌子变成这样

3 天前 · 12,400 播放

超出基线

杭州学院路 5 家咖啡评测

6 天前 · 7,200 播放

超出基线

完播率 28%

↓ -13.0 pp vs 你的基线

新增关注 12

↓ -22% vs 你的基线

转发 31

↓ -86% vs 你的基线

评论情感 混合

42% 困惑 vs 你的基线

归因 · 策略 VS 实际

发布前的策略假设

- 开场钩子：黑屏 + 一句话悬念
- 主线：跟拍 + 三段反差笑点
- 预估完播率：≥ 41%
- 验证假设：考研向是否能持续吸粉

发生了什么

- 钩子没拉住人 · 第 12s 流失 38%
- 笑点节奏 OK，但跨越点不明显
- 实际完播率：28% · 比基线低 13pp
- 评论里 42% 表达“没看懂在拍啥”

INSIGHT 01 数据驱动

12s 流失 -38%

完播率低于基线 13pp，主要发生在第 12 秒

INSIGHT 02 数据驱动

困惑评论占比 42%

42% 评论表达“没看懂”，主要是没看完悬念的人

DEMO

0. New user

1. Onboard

→ Profile

→ Ideate

→ Retro

→ Home

观众里，68% 留下了“啥意思”“看不懂”类

那么前置钩子 0.1%，那么后置钩子 0.1%。说明前置钩子有效，

比。无播放观众普遍正面。问题不在内容本身，在于钩子吊

A 小A

1,238 粉丝 · 抖音

RETRO ENGINE

在解读最近这期表现

Beacon

这条数据没炸，但是没价值。我归因了一下：

Beacon

钩子有效（前 12 秒留存 81%），但接下来的口播太冷拉不住人。这是节奏问题，不是选题问题。

完播曲线

评论聚类

Beacon

另外有个发现——它给你带来的新粉 83% 都是考研画像。我建议把这个写回画像引擎。点 Insight 03 可以详聊。

把考研向写回画像

下一条也做考研向

为什么钩子拉得住人但口播拉不住

下一步可以问

其他视频也帮我归因一下

评论里最尖锐的几条

给我导出一份复盘报告

问点关于“在解读最近这期表现”的事...

AI 会引用你的画像与最近数据。了解隐私

发送

换行

步骤6: Home



2.5 创新与差异化

2.5.1 当前市面 AI 工具的能力分布

类别	代表产品	核心定位	服务对象
内容生成型 AIGC	剪映 AI、Runway、Pika、腾讯智影、百度文心视频	替代拍摄 + 剪辑 + 编导 (文本→视频、数字人、一键成片)	任何想批量产内容的创作者
爆款工业化复刻	DoLabAI、即创、一帧秒创、MCN 内部系统	爆款拆解 → 模板复刻 → 多账号批量生成	中腰部 KOL、电商带货账号、MCN
KOC 营销 SaaS	微盟「发布有礼」、易创 AI、微播易	内容生成 + 任务激励 + 分发追踪	B 端品牌方、KOC 流量池
数据策略类	评论情绪分析、舆情 AI、内容推荐 AI	评论挖掘、热点识别、用户偏好建模	已经有规模的账号或品牌

2.5.2 Beacon 的位置：覆盖一个被忽视的窗口

上述 4 类工具有一个共同假设：用户已经知道自己要做什么内容、面向谁，工具只负责加速产出或优化分发。但早期 KOC（1K-10K 粉）最缺的恰恰是这个前置思考：

- 不缺剪辑工具 — 剪映免费就能用
- 不缺爆款模板 — 复刻爆款会丢掉个人色彩，反而稀释定位
- 不缺批量分发 — 一周一两条精品比每天发 10 条素材更重要
- 不缺数据看板 — 看了也不知道下一步该做什么

Beacon 占据一个空白窗口：早期 KOC 的「画像建立 + 战略导航 + 闭环复盘」。我们不是又一款剪辑工具，也不是又一个 KOC 流量池，而是创作者的**成长伙伴**。

2.5.3 四层独有差异点

1. AI 先做功课的 onboarding 范式
- 业界标配是「让用户填空白问卷」（即使披着对话外衣）。Beacon 在用户开口前已分析过其全部历史视频，第一句话就是带证据的假设。这把入场门槛从「教 AI 我是谁」反转为「让 AI 先猜，我来纠正」，对非专业用户更友好。
（注：在demo中历史视频的分析汇总由mock data代替）
2. 三态画像（确定 / 个性化 / 待探索）
- 主流画像产品只输出「标签云」或「确定项列表」。Beacon 把「**还在思考的方向**」视为长期追踪的对象——这正是早期 KOC 最焦虑的部分。AI 帮用户陪伴探索，而不是要求用户立刻决定。
3. 双轴策略 + 来源标签 强制契约
- 每条建议同时基于「画像驱动 + 趋势驱动」交叉判断，且必须明示来源（5 元枚举：画像驱动 / 趋势驱动 / 数据驱动 / 历史复盘 / 用户偏好驱动）。这是产品的**信任根基**。
4. 闭环可验证
- 策略阶段，产出策略快照中含 重点观察指标 ；复盘阶段以同类型历史基线（baseline_pillar）作为参考系，逐条对照「假设 vs 实际」，结果回写画像触发 profile_v{n+1} 升级。这一步让 AI **迭代式更新画像**，能够越来越懂用户。目前产品没有把 onboarding / ideate / retro 串成同一个数据契约。

模块三 AI 原生能力说明

3.1 AI 核心能力

Beacon 是一个AI agent原生产品，**没有 AI 则整个产品形态不成立**。所用 AI 能力包括：

AI 能力	在 Beacon 中承担的工作
用户对话	onboarding 多轮对话、ideate 选题精修、retro 追问、chat dock 全场景
结构化推理	画像生成、策略评估（4 维打分）、复盘归因
语义理解	消化历史视频脚本、评论聚类、视频退出形状特征解读、假设验证等多源信息
多 Agent 协作	4 个 agent（Onboarding / Strategy / Retro / Orchestrator）按状态机串联，设置3层memory分享机制

3.2 AI 如何解决用户痛点

每一个核心痛点的解决方案都直接绑定 AI 能力：

用户痛点	AI 绑定的解决能力	去掉 AI 会变成什么
定位模糊	LLM 消化全部历史视频 + transcript + 评论， 提出带证据的画像假设	退化为静态问卷，难以对用户客制化， 也没法引导用户探索新内容
选题没方法论	LLM 联合推理画像 + 趋势 + 历史指标， 给出双轴评估	丢失用户个性化推荐，难以让KOC产生差异化
复盘能力弱	LLM 对照策略意图与实际数据做归因， 挖掘评论语义理解数据	退化为数据看板， 没法根据多源信息得到详细结论

3.3 AI 技术方案

3.3.1 模型选型


主模型：DeepSeek v4，三档调度：

模型档位	用途	选用agent状态
pro-thinking （高质量 + 高延迟）	关键深度推理	Onboarding ANALYZE / Strategy SCORE+STRATEGIZE / Retro COMPARE+ATTRIBUTE+SYNTHESIZE
flash-thinking （中延迟 + 中等推理）	对话式生成	所有 PRESENT / REFINE / EXPLORE / DRILL / Orchestrator 对话
flash （最低延迟 + 快速分类）	简单分类	Onboarding VALIDATE 动作分类 / Orchestrator router

为什么是 DeepSeek v4：国产可控、价格低廉、推理质量在中文模型非常高，KV cache hit rate极高导致响应快。

3.3.2 Agent 架构总览

Beacon 共 4 个 agent，每个 agent 都遵循统一的**「有限状态机 + 三层 memory + 多段 prompt + schema 强校验」**
范式：



4 个 agent 的职责：

- **Onboarding Agent**：把账号原始数据通过多轮对话翻译成一份带证据的三态画像 profile_v1.json)
- **Strategy Agent**：把一个 idea 翻译成可执行、可被复盘消费的策略快照（含 重点观察指标 锚点，存为 strategy_snapshot_{id}.json)
- **Retro Agent**：把一条已发布视频的数据 + 评论翻译成结构化洞察 + 画像更新（存为 insights_report_{id}.json + profile_v{n+1}.json)
- **Orchestrator Agent**：把 chat dock 里的一句话翻译成带来源标签的回复 + follow-up 建议

3.3.3 三层 Memory（每个 agent 共享的范式）

Layer	说明	是否进 prompt
L1 会话工作记忆	当前状态相关切片 + 最近 4-6 轮对话，按阶段裁剪	✅ 每次进

Layer	说明	是否进 prompt
L2 会话持久化记忆	完整分析/报告、对话历史、状态切换日志	✗ session 内可调
L3 跨模块共享	用户画像 / strategy_snapshot / insights_report 三个 store，是 agent 间的契约接口	✗ 通过 schema 消费

3.3.4 Schema 强校验

所有结构化输出阶段必须通过schema 校验：


- profile_v{n}.json — 三态结构 + 观众假设 + 过往内容校验
- strategy_snapshot.json — 热点分析 / 画像契合度 / 差异化 / 执行（含重点观察指标）
- insights_report.json — 数据卡 / 策略回顾 / 深入分析 / 建议 / 观众信号

3.3.5 预跑缓存策略

为保证 demo 稳定性，以下深度推理阶段强制预跑并缓存到 cache/*.json：

阶段	缓存文件	缓存原因
Onboarding ANALYZE	cache/onb_analyze.json	无法一次性深度分析 12-15 条视频，demo缺乏外部接口
Strategy SCORE + STRATEGIZE	cache/strategy_score_strategize.json	复杂联合推理，方差大
Retro COMPARE + ATTRIBUTE + EXTRACT_SIGNALS + SYNTHESIZE	cache/retro_synthesis.json	归因分析耗时长，且完全依赖mock data，不需要重复生成

3.3.6 工作流总览



3.3.7 各 Agent 的前置输入与未来扩展方向

本节明示每个 agent 当前假设已知的输入（demo 中由 mock 提供，未来需要真实接入）与接下来可以更完善的方向（按优先级 P0 / P1 / P2 标注：P0 = 上生产前必做，P1 = 重要扩展，P2 = 长期加分）。

Onboarding Agent

维度	内容
假设已知（输入）	· 账号身份信息（昵称 / 粉丝数 / 平台 / 注册时长） · 12-15 条历史视频元数据（标题 / 标签 / 发布时间 / 各项指标 / drop_off 曲线 / 完整脚本） · 每条视频 5-10 条评论文本 · 现有粉丝画像快照（年龄 / 性别 / 地域 / 兴趣分布）
当前 demo 简化	· 上述全部由 mock_data/*.json 提供，未真接入抖音 / 小红书 OAuth · 脚本直接给文本，未经转写流程 · ANALYZE 阶段走 cache/onb_analyze.json 兜底，不在现场跑 LLM

维度	内容
未来可扩展方向	[P0] 真实平台数据接入：对接抖音 / 小红书 / B 站开放平台 OAuth + 数据抓取，替换 mock_data 通路 [P1] 跨 session refresh：spec 已预留 session_origin 字段，后续支持每月 / 每季度自动重新 onboarding，识别画像漂移 [P1] 大样本承载：当前 12-15 条上限，真实账号可能数百条，需加分批 ANALYZE 与摘要压缩 [P1] 冷启动用户兜底：粉丝数 < 100 / 视频 < 5 条时数据稀薄，需要降级路径（更多引导式提问 + 更少假设） [P2] 多模态消化：当前只读脚本与指标，未来引入封面图 / 关键帧 / 音频特征，画像维度更立体 [P2] 画像导出与互操作：开放画像 JSON 导出 / 第三方接入接口，让画像成为创作者可携带的数字资产

Strategy Agent

维度	内容
假设已知（输入）	• 最新版本画像 profile_v{n}.json（消费自 Onboarding 输出，含三态、观众、过往分析） • 当前平台 2-3 个候选热度主题数据（热度曲线 / 方向） • 用户提交的 idea 文本（idea-driven 模式）或空白请求（discovery 模式） • 历史指标基线（account_baseline.json，用于"贴合度"中的同类对比）
当前 demo 简化	• 热度数据由 mock_data/external_trends.json 提供，未接真实趋势 API • Demo 主线只走 idea-driven 路径；spec 中 discovery / system-triggered 模式已有 GENERATE_IDEAS 状态但未在演示路径展示 • SCORE + STRATEGIZE 阶段走 cache/strategy_score_strategize.json 兜底 • Idea 输入仅支持文本（语音 / 图像按钮预留但不实现）
未来可扩展方向	[P0] 真实趋势数据源：对接抖音热点榜 / 小红书趋势 API / 微博热搜 / 百度指数等，建立趋势数据中台 [P0] Discovery 模式产品化：用户没思路时由待探索项主动 GENERATE_IDEAS 给 2-3 个候选，每条标注"能验证什么假设" [P1] System-triggered 主动建议：proactive AI 在画像出现高优先级待探索项时主动推送"我们可以做一期 X 来验证 Y"通知 [P1] 拍摄简报增强：在执行字段基础上补充 storyboard / 镜头清单 / 钩子 脚本草稿，从"策略"延伸到"准生产输出" [P1] A/B 策略并行：同一 idea 给 2 个差异化版本策略，发布后由 retro 阶段做对照归因 [P2] 跨平台策略适配：同一 idea 在抖音 / 小红书 / B 站的 钩子 与 pacing 自动调整 [P2] 多模态 idea 输入：用户用语音口述 / 上传参考图，agent 理解后转为结构化 idea

Retro Agent

维度	内容
假设已知（输入）	• 最新版本画像 <code>profile_v{n}.json</code> • 这条视频对应的策略快照 <code>strategy_snapshot_{id}.json</code>（含 重点观察指标锚点与各项执行假设） • 已发布视频数据：指标（播放 / 完播 / 点赞 / 评论 / 转发 / 关注转化 / 收藏）+ <code>drop_off</code> 曲线（秒级抽样）+ <code>transcript</code> • 评论池：理想数百条，含可触发 <code>insight</code> 的内容反馈 / 受众反馈 / 矛盾点 • 历史指标基线 <code>account_baseline.json</code>（整体 + 同分类历史均值，用于判定）
当前 demo 简化	• 全部数据由 <code>mock</code> 提供；预生成 <code>vid_016 / vid_019 / vid_020</code> 三条候选报告，主线走 <code>vid_019</code> • <code>COMPARE / ATTRIBUTE / EXTRACT_SIGNALS / SYNTHESIZE</code> 走 <code>cache/retro_synthesis.json</code> 兜底 • 评论数量稀薄（5–10 条 / 视频），未做大规模聚类与噪声过滤 • "假设视频已发布"：从 <code>ideate</code> 提交后直接跳 <code>retro</code>，跳过真实的发布 → 等待 → 数据稳定流程 • <code>Spec</code> 中 <code>batch-review</code>（周 / 月级跨视频复盘）模式 <code>demo</code> 不演示
未来可扩展方向	[P0] 真实视频数据接入：与 <code>Onboarding</code> 的平台 <code>API</code> 通路共用，发布后自动拉取 <code>metrics</code> + 评论 [P0] Auto-trigger 自动复盘：发布后 24–48h 数据稳定时自动生成报告并推送，把"主动关心"做成产品可感知的体感 [P1] 大规模评论处理：上千条评论的语义聚类 + 噪声 / 灌水过滤 + 风险评论标识（黑粉 / 网络暴力） [P1] Batch-review 周期复盘：每周 / 每月对一组视频做 <code>meta</code> 级跨视频归因，识别"反复出现的 钩子 失效模式"等共性规律 [P1] 多模态归因：<code>drop_off</code> 时点与实际画面 / 音频片段对齐，识别"是文案问题 / 画面问题 / 节奏问题" [P1] Retro → Ideate 直通：复盘结束后"下一条做什么"按钮直接带着 <code>insight</code> 进 <code>ideate</code>，让闭环形成正反馈 [P2] 跨平台复盘合并：同一视频在抖音 + 小红书 + B 站的数据合并归因（跨平台基线对齐是难点） [P2] 长记忆归因：模型保留每个 <code>KOC</code> 的全部复盘历史，做更细颗粒的"个人化归因模型"

Orchestrator Agent

维度	内容
假设已知（输入）	• 当前 <code>scene</code> 标识（<code>home / onboard / profile / ideate / retro</code> 五选一） • 当前轮 <code>user_text</code>（≤ 2000 字符） • 最近若干轮 <code>chat_history</code>（<code>router</code> 实际只看末 6 项里最近 2 轮 <code>user/ai</code>） • 可选 <code>focused_element</code>（用户点击的元素 <code>id</code>，预留字段当前不消费） • 文件系统中其他 <code>agent</code> 写下的产物：<code>profile_v{max_n}.json</code> / 最新 <code>strategy_snapshot_*.json</code> / 最新 <code>insights_report_*.json</code>，按 <code>router</code> 决策的 <code>needs_slices</code> 子集装配

维度	内容
当前 demo 简化	• 无状态记忆：每一次调用都从前端把 chat_history 传回来，后端不持久化任何对话 • 单画像：只有一个 user_id 对应一套 runtime_data，没有用户隔离 • 前端硬路由两条路径绕过 Orchestrator：scene=ideate 且已有 snapshot → strategy/refine；scene=retro 且已有 report → retro/drill • Source guard 缺 tag 时只做 1 次 retry + fallback 注入，没有离线监控管道分析触发率 • Chat dock 只支持文本输入，图像按钮预留但不实现 • Router 失败时回退到保守 FALLBACK_DECISION（挂全部三个切片），未做更精细的降级
未来可扩展方向	[P0] 多用户隔离：runtime_data 按 user_id 分目录，鉴权与会话路由完整化（上生产前必做） [P0] 来源标签 离线监控管道：used_fallback=true 事件做 ETL 入数仓，监控 fallback 触发率与 source 分布，是产品质量的核心指标 [P1] 跨 session 长记忆：用户在不同时间提到的偏好 / 决策 / 取舍沉淀为长记忆，下次自动召回（当前完全靠前端 zustand） [P1] Proactive AI 通知中枢：复盘到位、画像漂移、新趋势涌现等触发主动消息，从 reactive chat 升级为 proactive partner [P1] 多模态对话：用户上传截图 / 视频片段 / 语音追问，结合视觉与音频上下文回答 [P1] 个人语气适配：根据用户既往回应风格调整 tone（简洁 / 详尽 / 共情 / 数据流），写入 profile 用户偏好驱动池 [P2] 团队协作：MCN / 工作室场景下，多个 KOC 共用同一团队画像，Orchestrator 区分"个人 vs 团队"语境 [P2] 更多 scene 接入：商单匹配 / 数据看板 / 同行对比等扩展模块，Orchestrator 只需新增 scene_<name>.txt prompt

模块四 加分项

4.1 落地可行性

技术成熟度：

- 前端：React 18 + Vite + TypeScript + Tailwind + Radix/shadcn — 全部主流稳定栈
- 后端：Python 3.11 + FastAPI + pydantic v2 — LLM 生态最成熟语言
- LLM：DeepSeek v4 OpenAI-compatible 接口，对接成本极低
- 部署：腾讯云 COS（前端静态托管）+ CloudBase / SCF（后端容器）+ DeepSeek API

开发节奏（实际进度 · 截至 2026-05-06）：

里程碑	状态
M0 项目初始化	✓
M1 Mock 数据与 Schema	✓

里程碑	状态
M2 设计 Tokens 与 Shell	✓
M3 5 个 Scene 静态实现	✓
M4 Onboarding Agent	✓
M5 Strategy Agent	✓
M6 Retro Agent	✓
M7 Orchestrator + 来源标签	✓
M8 闭环演示与故事线打磨	🟡 进行中
M9 腾讯云部署	✓

所需资源评估（小规模上线版本）：

- 1 名全栈工程师持续投入（已由参赛个人 + Claude Code 协作完成 demo）
- 腾讯云：1 个 COS 桶（前端）+ 1 个 SCF 函数 / CloudBase 容器（后端）+ HTTPS 证书
- DeepSeek API key：单 key 驱动三档模型，按用量计费
- 风险点：真实落地的关键依赖是**平台数据接入**（抖音 / 小红书开放 API 或用户授权），demo 阶段以 mock 数据规避

4.2 商业化思考

目标市场分层：

阶段	服务对象	模式
短期（0–6 个月）	C 端早期 KOC（1K–10K 粉）	免费版 + 增值订阅（更高频 retro、更长画像历史、自定义话题）
中期（6–18 个月）	B 端 MCN 机构 / 校园运营团队	按席位订阅，多账号画像批量管理，跨账号 insight 复盘
长期（18 个月+）	平台 / 品牌方	商单匹配抽佣（Beacon 沉淀的画像与策略历史是天然资产）、平台数据合作、品牌定制 insight 服务

竞争优势锚点：

1. **场景占位**：早期 KOC 画像 + 战略导航是被现有工具忽视的窗口，先发占位
2. **数据飞轮**：每个用户的「画像 → 策略 → 复盘」闭环都在沉淀结构化数据，越多用户越能反哺模型与策略库
3. **信任契约**：来源标签 + schema 校验把 AI 黑箱透明化，是用户长期留存的根基
4. **平台无关**：所有 schema 中的 platform 字段为枚举，可同一画像支撑多平台运营，未来扩展成本低

5 产品设计复盘

目的：本复盘不记录工程难题，只总结 demo 准备过程中关于 AI 产品体验、信任设计、流程编排的方法论启示，供未来做产品时参考。

5.1 等待真空 — 让用户实时看到 AI 在做什么

LLM 推理有不可消除的延迟，几秒到几十秒都正常。如果界面只显示 spinner，用户会陷入"真空"——不知道 AI 是在思考还是已经卡死，几秒就开始焦虑。

真实等待时间和体感等待时间是两件事。在不能让模型更快的前提下，让用户**看到 AI 正在做什么**就足以解决体感问题：流式逐字渲染、流式 thinking 过程、侧边栏实时显示"AI 已经记录到什么"、状态步骤可见化、结果预加载。所有这些手段成本都很低，价值远大于换更快的模型。

启示：设计 AI 产品时，第一条需求应是"每个等待节点用户能看到什么"。任何超过 2 秒的等待都必须有内容填充，哪怕只是一行"正在分析..."。让 AI 的工作过程**可见**，比让 AI **变快**更有杠杆。

5.2 透明度即信任 — 让用户校验得到 AI 的依据

用户对 AI 建议天然怀疑"凭什么"。如果 AI 给出结论却说不出依据，结果只有两种：盲从（误导风险）或不信（卸载风险）。**信任不能靠营销文案，必须做进交互。**

迭代过程中我们把透明度逐步做深：从纯自由文本，到每条消息标注来源，再到把推理过程摊开成可点击的结构化元素，让用户能向下追问任意一个数据点。每多展示一层依据，用户对建议的接受度就上一个台阶。当 AI 没有依据时，**承认"不知道"比编造一个更能积累长期信任。**

启示：把"模型输出"和"模型依据"分别渲染，比混在一起的可信度高一个量级。在写第一行 prompt 之前，先想清楚"用户怎么校验这个输出"——校验不到，就不要让 AI 输出。

5.3 Orchestration 即产品力 — 自动化是降低阻力的根本手段

非专业用户最怕复杂操作。每多一步决策都是流失风险。如果让用户自己安排"什么时候该做 A / 什么时候该做 B / 哪个 agent 处理我的问题"，认知门槛立刻拉高，产品价值被 UI 复杂度抵消。**对非专业用户而言，自动化本身就是产品力。**

Agent 编排不只是技术架构选择，更是产品体验的核心设计。架构上把多个 agent 串起来不难，难的是让用户感知上是"一个伙伴在帮我"，而不是"几个工具我要分别学"。这要求 orchestration 同时承担三件事：路由决策（用户不必知道哪个 agent 在处理）、状态衔接（上一步产物自动作为下一步输入）、路径压缩（默认动作自动执行，只在真有歧义时让用户选择）。

启示：每加一个 UI 元素都先问"这一步能不能不让用户做"。能不让做的就不做，能默认就默认。让用户的决策预算只花在真正重要的事上——也就是他们的创作本身。

附录：完整技术资料索引

本主文档面向产品介绍，详细技术内容请在GitHub repo见以下附录文件：

附录编号	文件	内容	行数
附录 A	PRD.md	完整产品需求文档：模块详细规范、数据模型、技术栈、部署架构、开发路线图	~1054行
附录 B	onboarding_agent_demo_spec.md	Onboarding Agent 详细技术规范：8 状态 FSM、三层 memory、6 段 prompt、profile schema	~376行
附录 C	content_strategy_agent_demo_spec.md	Strategy Agent 详细技术规范：8 状态 FSM、三层 memory、6 段 prompt、strategy snapshot schema	~469行
附录 D	retro_insight_agent_demo_spec.md	Retro Agent 详细技术规范：9 状态 FSM、三层 memory、8 段 prompt、insights report schema	~609行
附录 E	orchestrator_agent_demo_spec.md	Orchestrator Agent 详细技术规范：两阶段 LLM、5 scene prompt、RouteDecision schema、source guard	~230行